

Análisis Avanzado de Agrupamiento sobre el Dataset Fashion MNIST

Juan García-Tizón Dans - j.gdans@udc.es

Pablo David Cobelo García - p.d.dcobelo@udc.es

1. Introducción y Contexto del Problema

La presente práctica se centra en el desafío de organizar de forma automática una colección de imágenes pertenecientes al dataset Fashion MNIST mediante técnicas de aprendizaje no supervisado. A diferencia del clásico conjunto de dígitos manuscritos, este dataset introduce una complejidad morfológica superior, donde texturas, longitudes de manga y sutiles diferencias de diseño entre prendas de vestir ponen a prueba la capacidad de discriminación de los algoritmos de clustering. El objetivo fundamental ha sido explorar cómo la estructura de datos latente puede emerger sin la ayuda de etiquetas, utilizando un flujo de trabajo que combina el refinamiento de imágenes, la reducción de dimensionalidad y el modelado probabilístico.

2. Tratamiento y Preparación de la Información


El éxito de cualquier proceso de agrupamiento depende críticamente de la calidad de los datos de entrada. En primer lugar, se realizó una auditoría del dataset que confirmó un equilibrio perfecto entre las clases; al disponer de la misma cantidad de imágenes por categoría, se garantizó que los algoritmos no se vieran sesgados hacia grupos mayoritarios por una cuestión de densidad numérica.

Un paso diferenciador en este estudio fue la aplicación de una técnica de **recorte o "crop"** de las imágenes. Se identificó que una parte significativa de los 28x28 píxeles originales correspondía a fondo negro sin información útil. Al recortar estos bordes, logramos eliminar características comunes irrelevantes —píxeles con varianza cero— que suelen actuar como ruido en el cálculo de distancias. Este refinamiento permitió que los modelos se concentraran exclusivamente en la esencia de la prenda, mejorando la eficiencia computacional y la precisión del agrupamiento. Posteriormente, se aplicó una normalización estándar para asegurar que las variaciones de intensidad lumínica no distorsionaran la geometría del espacio de características.

3. Estrategia de Reducción de Dimensionalidad y Búsqueda de Hiperparámetros

Antes de simplificar el problema, se llevaron a cabo experimentos iniciales aplicando los

métodos del **Codo (Elbow)** y del **Coeficiente de Silueta** directamente sobre los datos en bruto. Es interesante observar que, desde un punto de vista puramente matemático, las gráficas sugerían de forma consistente un valor de $K=7$. Esto indica que, a nivel de píxeles, existen al menos tres categorías de prendas que son tan similares entre sí que los algoritmos tienden a fusionarlas. Sin embargo, en un ejercicio de integración entre la estadística y el conocimiento del dominio, decidimos mantener la configuración de $K = 10$. Esta decisión se justifica por la naturaleza intrínseca del dataset (que contiene 10 categorías reales) y el objetivo de lograr una segmentación que sea funcionalmente interpretable para un usuario humano.



Para facilitar esta tarea, se implementó el Análisis de Componentes Principales (**PCA**). Esta transformación no fue solo una medida de eficiencia; fue una herramienta para combatir la "maldición de la dimensionalidad". Al proyectar las imágenes en un espacio de componentes principales, logramos filtrar las variaciones de alta frecuencia y centrar el agrupamiento en las estructuras de varianza más significativas, lo que resultó en clusters más cohesivos y mejor definidos.

4. Discusión Crítica de los Algoritmos y Resultados

A lo largo de la comparativa, el Modelo de Mezclas Gaussianas (**GMM**) con una configuración de covarianza diagonal emergió como la técnica más robusta, superando al clásico K-Means en la métrica V-Measure. Esta superioridad radica en la flexibilidad del GMM para adaptarse a distribuciones que no son perfectamente esféricas; mientras que K-Means asume que todos los clusters tienen formas redondas y tamaños similares, el GMM pudo capturar la naturaleza elíptica de ciertas prendas en el espacio de características.

Por otro lado, la inclusión de **DBSCAN** en la comparativa proporcionó lecciones valiosas sobre la densidad del dataset. A pesar de su capacidad para detectar ruido y formas arbitrarias, DBSCAN presentó dificultades significativas debido a que las densidades de las diferentes prendas de vestir en el espacio PCA son muy parecidas. Ajustar un radio que no colapsara los datos en un solo grupo o que no los descartara masivamente como valores atípicos resultó ser una tarea extremadamente sensible, confirmando que para datos de imagen de alta densidad

uniforme, los métodos paramétricos suelen ser más estables.

Desde una perspectiva visual, el análisis de los clusters reveló patrones fascinantes. Existe una "isla" de alta precisión que agrupa de forma casi perfecta al calzado (botines, sandalias y zapatillas) y los bolsos. Estos elementos poseen una firma geométrica única. Por el contrario, se identificó un "punto crítico de confusión" entre camisetas, camisas y abrigos. Incluso con el preprocesado de recorte, la arquitectura básica de estas prendas es tan similar que el aprendizaje no supervisado encuentra sus límites, sugiriendo que para separar estas clases se requerirían características más profundas o un enfoque semántico superior.

5. Conclusiones finales

La práctica demuestra que el clustering de imágenes es un proceso híbrido entre la computación y la toma de decisiones basada en el contexto. El preprocesado mediante el recorte de imágenes y la reducción estratégica de dimensiones a través de PCA demostraron ser tan determinantes para el resultado final como la elección del propio algoritmo. Aunque las métricas matemáticas puedan sugerir agrupamientos más simplificados, la persistencia en el uso de diez clases permitió validar que el conocimiento previo del problema es esencial para interpretar correctamente la estructura de los datos. En última instancia, la combinación de GMM con una proyección visual mediante t-SNE ha proporcionado la herramienta más completa para comprender cómo la moda se organiza de forma natural en el mundo digital.